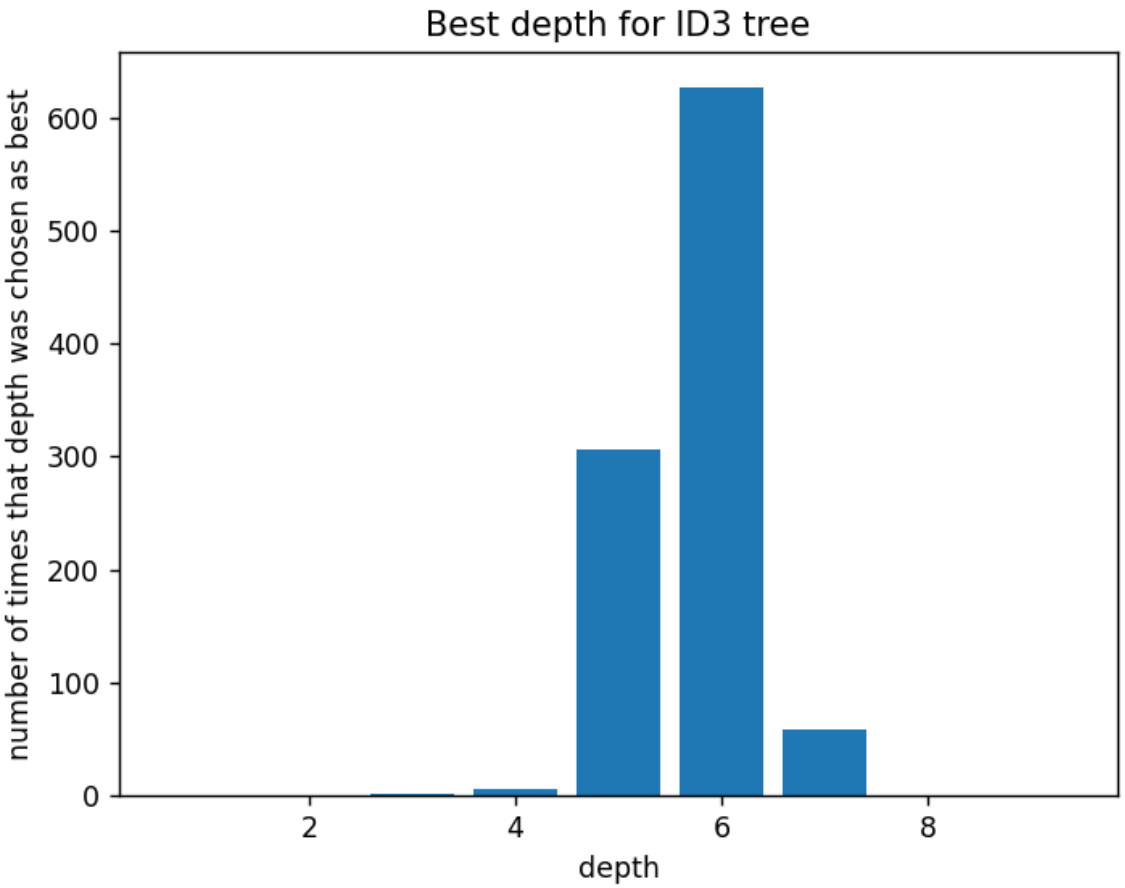
Regresja i klasyfikacja

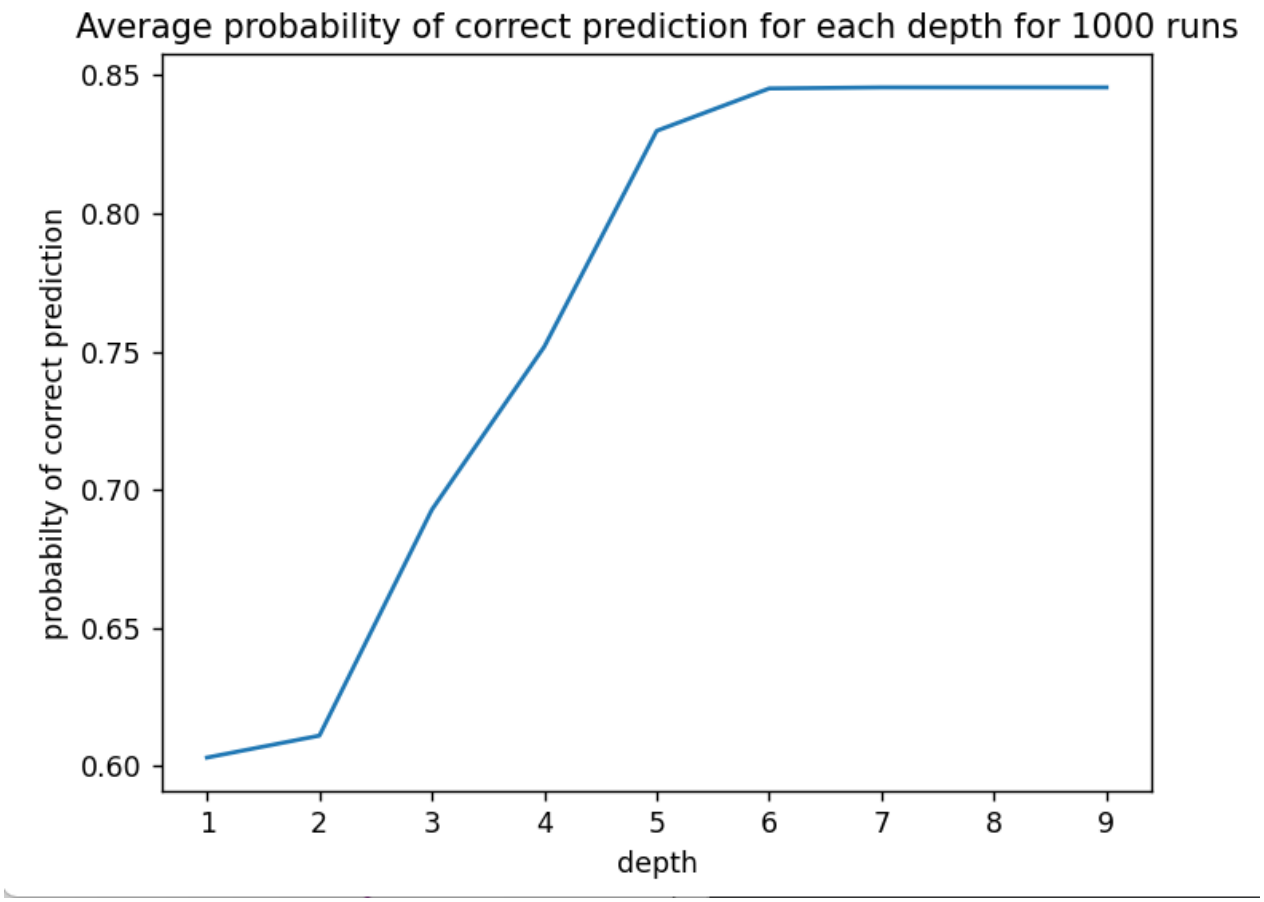
Cezary Jankowski

1. Sprawdzenie najlepszej głębokości



Głębokość	Ile razy wybrana jako najlepsza	Procentowo
1	0	0%
2	0	0%
3	2	0,2%
4	6	0,6%
5	306	30,6%
6	627	62,7%
7	59	5,9%
8	0	0%
9	0	0%

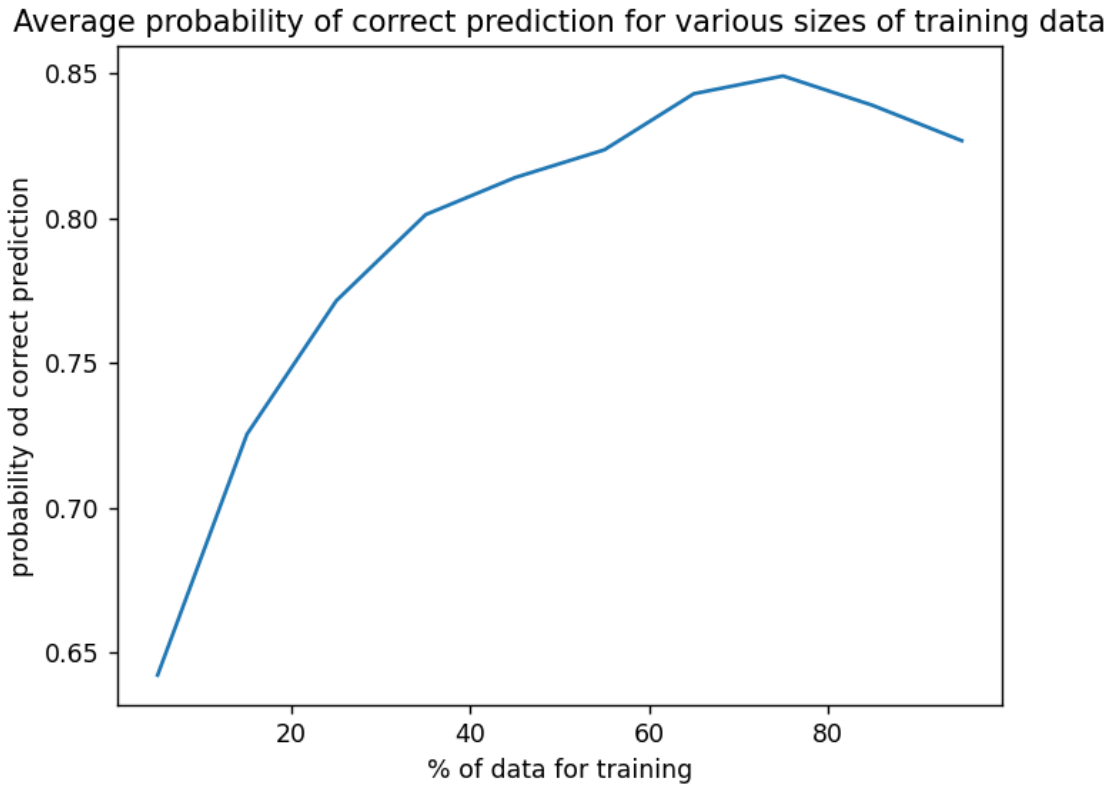
Możemy zauważyć, że praktycznie zawsze jako najlepsza wybierana jest głębokość 5 lub 6. Dla zbyt małego drzewa podział danych jest zbyt ogólny, więc wyniki nie są najlepsze. Dlaczego glębokosci 8 i 9 ani razu nie zostaly wybrane pomimo tego że dobrze przewidują wynik? Kwestia oszczędności, jezeli dla glebokosci 6 i 8 otrzymujemy takie same rezultaty to wydajniejszym jest budowac mniejsze drzewo.



Rysunek 1: Średnie prawdopodobieństwo dobrego wyniku względem głębokości

Głębokość	Średnie prawdopodobieństwo dobrego wyniku
1	0.60
2	0.61
3	0.69
4	0.75
5	0.82
6	0.84
7	0.84
8	0.84
9	0.84

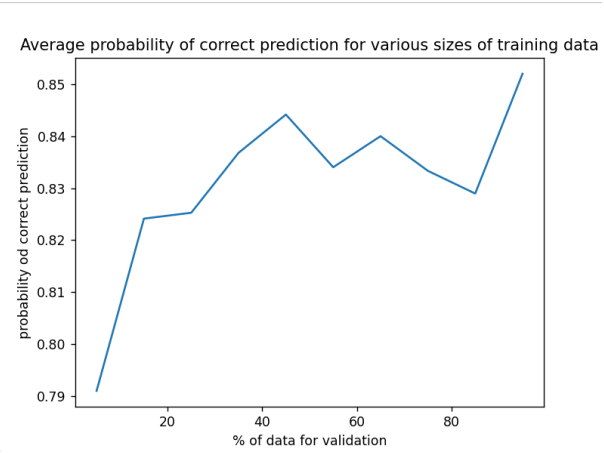
2. Podział danych na treningowe i reszte

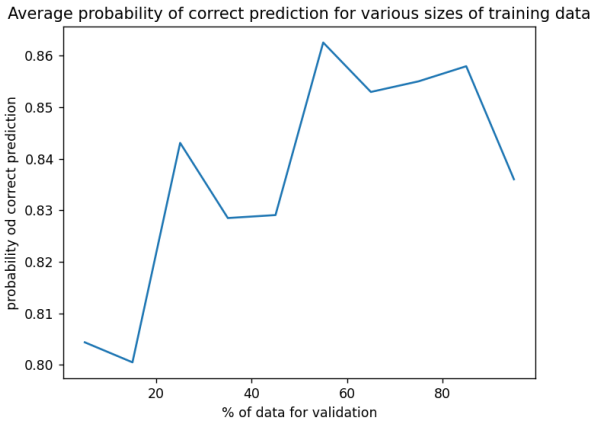


Z pozostałych danych wykonano równy podział na walidacyjne i testowe.

Najlepiej dać około 75% danych do trenowania drzewa. Co do zasady, im więcej danych, tym lepiej, ale powyżej około 80% widzimy tendencję odwrotną. Zaczyna brakować danych do efektywnego znajdywania najlepszej głębokości drzewa, przez co późniejsze testy są gorsze.

3. Podział pozostałych danych na walidacyjne i treningowe





Tutaj za rozsądny podział mozna uznać 50/50. Mała ilość danych walidacyjnych często nie wystarcza do znaleznienia najlepszej głębokości drzewa. Z kolei dużo dancyh walidacyjnych oznacza mało danych testowych, dlatego na wykresie możemy zaobserwowac różne wyniki dla wyskich ilosci danych walidacyjnych. Mało testów nie pozwala na wyrobienie odpowiednio dużo wyników aby uśrednić prawdobodobieństwo.

3. Uśredniona macierz pomyłek i dokladnosc dla 50 wykonań

Dla podziału danych 70% treningowe 15% walidacyjne 15% testowe

True Positive	81.98
True Negative	38.12
False Positive	12.12
False Negative	11.78

Dokładność : 83,5%

4. Wnioski

- Dobry podział danych to np. 75% treningowe 12,5% walidacyjne i 12,5% testowe.
- Najlepsza głębokośc drzewa to 5 lub 6.
- Nie występuje przetrenowanie