Uczenie ze wzmocnieniem

Cezary Jankowski

1 Analiza kosztów (Q-Table)

Początkowym celem projektu było nauczenie agenta wyznaczania najlepszej trasy. Tablice ruchów oraz ich wartości były na bieżąco zapisywane. Po nauczeniu agenta otrzymano tabelę, która przedstawia przybliżony koszt dotarcia do celu dla każdego stanu. Poniżej znajduje się kompletne zestawienie wartości dla wszystkich stanów:

Pełna tablica wartości dla wszystkich stanów

Stan	**Góra**	**Prawo**	**Dół**	**Lewo**
0	-15.00	-14.00	-14.00	-15.00
1	-14.00	-13.00	-13.00	-15.00
2	-13.00	-12.00	-12.00	-14.00
3	-12.00	-11.00	-11.00	-13.00
4	-11.00	-10.00	-10.00	-12.00
5	-10.00	-9.00	-9.00	-11.00
6	-9.00	-8.00	-8.00	-10.00
7	-8.00	-7.00	-7.00	-9.00
8	-7.00	-6.00	-6.00	-8.00
9	-5.99	-5.00	-5.00	-7.00
10	-4.98	-4.00	-4.00	-5.94
11	-3.99	-3.96	-3.00	-4.82
12	-15.00	-13.00	-13.00	-14.00
13	-14.00	-12.00	-12.00	-14.00
14	-13.00	-11.00	-11.00	-13.00
15	-12.00	-10.00	-10.00	-12.00
16	-11.00	-9.00	-9.00	-11.00
17	-10.00	-8.00	-8.00	-10.00
18	-9.00	-7.00	-7.00	-9.00
19	-8.00	-6.00	-6.00	-8.00
20	-7.00	-5.00	-5.00	-7.00
21	-6.00	-4.00	-4.00	-6.00
22	-5.00	-3.00	-3.00	-5.00
23	-4.00	-3.00	-2.00	-4.00
24	-14.00	-12.00	-14.00	-13.00
25	-13.00	-11.00	-113.00	-13.00
26	-12.00	-10.00	-113.00	-12.00
27	-11.00	-9.00	-113.00	-11.00
28	-10.00	-8.00	-113.00	-10.00

Stan	Góra	Prawo	Dół	Lewo
29	-9.00	-7.00	-113.00	-9.00
30	-8.00	-6.00	-113.00	-8.00
31	-7.00	-5.00	-113.00	-7.00
32	-6.00	-4.00	-113.00	-6.00
33	-5.00	-3.00	-113.00	-5.00
34	-4.00	-2.00	-113.00	-4.00
35	-3.00	-2.00	-1.00	-3.00
36	-13.00	-113.00	-14.00	-14.00

Dla pól przy krawędzi można zaobserwować koszt równy -113. Jest tak ponieważ kara za wpadnięcie do dziury wynosi -100, a później nadal musimy dodać koszt najlepszej ścieżki, czyli -13. Co ważne wyniki te były otrzymane dla discount factor = 1

2 Parametry uczenia

2.1 Learning rate

Za dobry learning rate można przyjąć taki w przedziale 0.4 – 1. Wysoki learning rate szybko wymazuje stare doświadczenia i zastępuje je nowymi, ale w naszym środowisku to nie problem ponieważ tutaj klif powinien być unikany za wszelką cenę i nic nie tracimy na tym że szybko odrzucimy go jako potencjalną ścieżkę.

	Epoka 0	Epoka 10	Epoka 20	Epoka 30	Epoka 40	Epoka 50	Epoka 60	Epoka 70	Epoka 80	Epoka 90	Epoka 100
LR = 0.01	5115.9	500.0	500.0	500.0	500.0	500.0	500.0	500.0	500.0	500.0	500.0
LR = 0.1	5076.1	584.7	500.0	441.8	344.2	344.6	403.0	461.0	480.5	422.6	480.6
LR = 0.2	**4699.7**	728.6	480.5	188.6	91.2	52.2	110.7	91.6	207.9	188.5	246.8
LR = 0.3	4870.6	986.2	344.2	71.4	32.6	13.1	13.1	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.4	5023.2	568.9	344.2	71.6	13.1	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.5	5139.3	771.1	227.4	91.0	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.6	4965.4	677.7	227.4	32.5	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.7	4953.4	**470.5**	149.4	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.8	5163.6	680.8	**71.7**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 0.9	5005.1	1472.4	227.3	13.2	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**
LR = 1	4926.1	908.2	84.2	13.1	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**	**13.0**

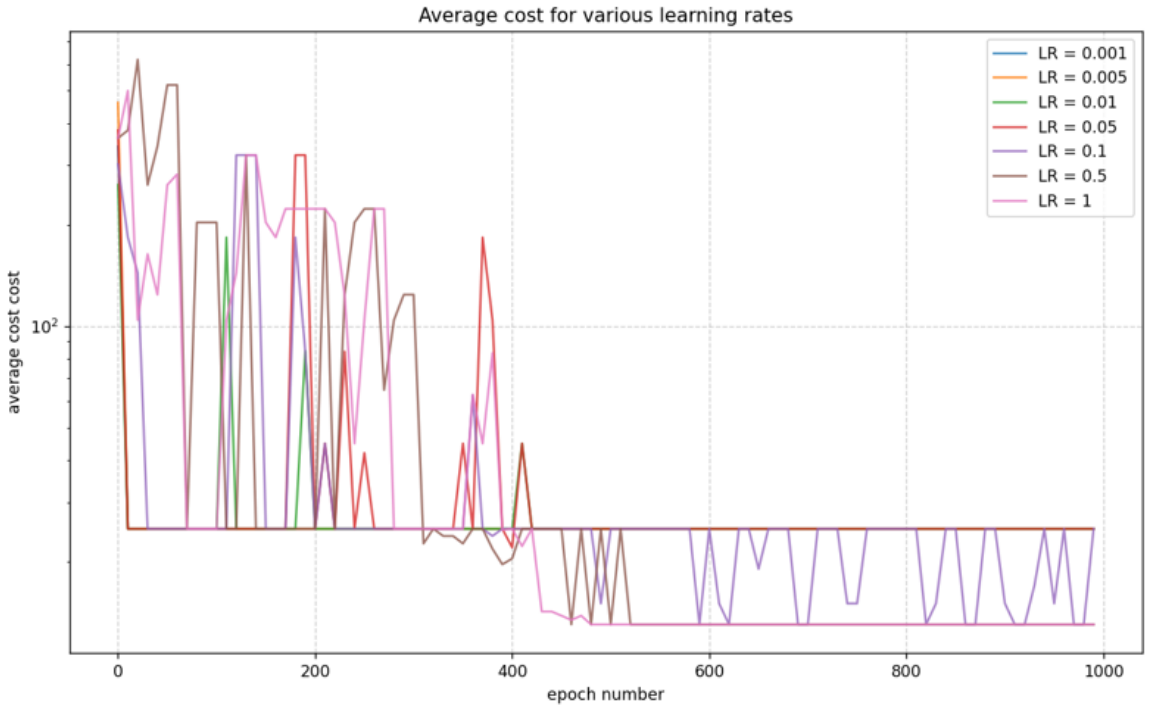
Wpływ parametru Learning Rate na proces uczenia.

2.2 Ilość kroków na epokę

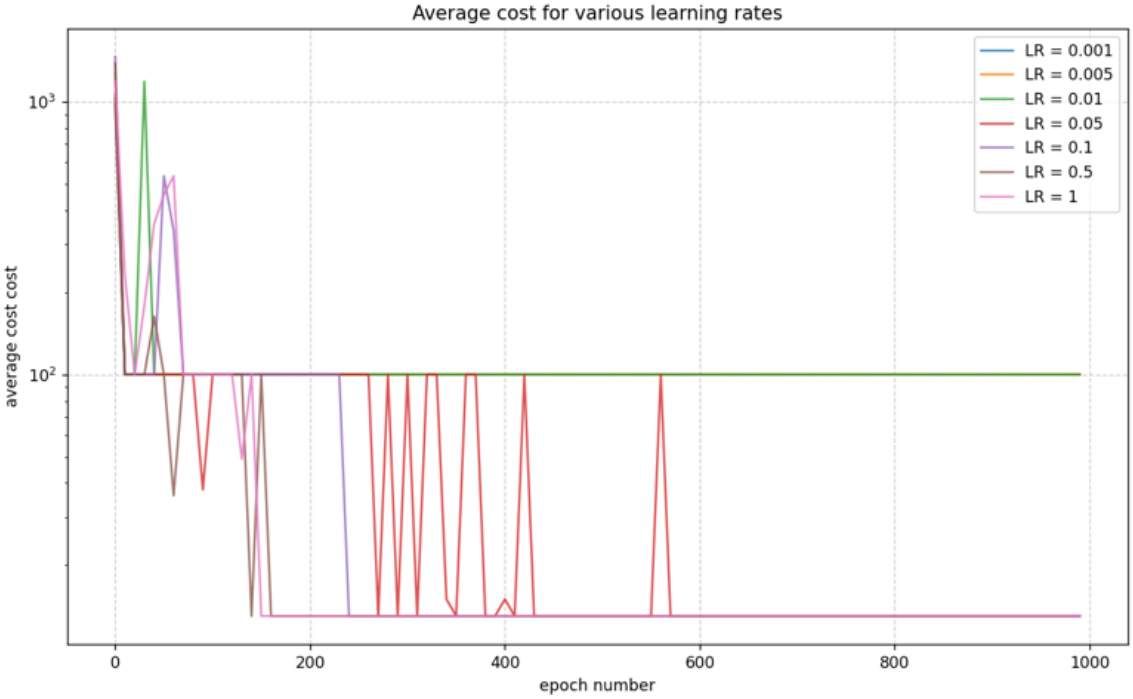
Ważnym czynnikiem decydującym o znalezieniu drogi jest ilość maksymalnych kroków na epokę. Epoka kończy się w dwóch przypadkach:

- kiedy agent znajdzie cel,
- kiedy osiągnie maksymalną ilość możliwych kroków.

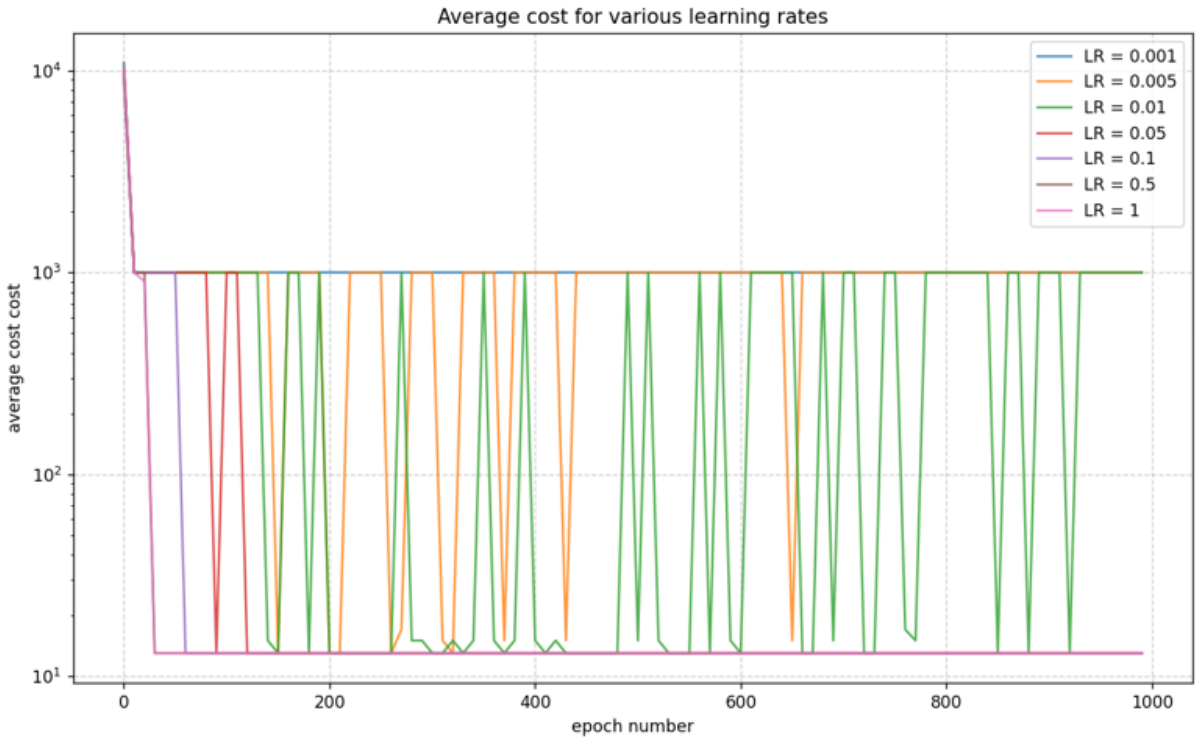
Ważnym jest (szczególnie w początkowych fazach uczenia) pozwolić agentowi na swobodne poruszanie się po mapie. Zwiększamy w ten sposób jego szanse na znalezienie celu.



Maksymalnie 25 kroków na epokę.



Maksymalnie 100 kroków na epokę.



Maksymalnie 1000 kroków na epokę.

Często jest widoczne przekraczanie na początku wykresu wartości liczby kroków, jest to spowodowane tym że w tamtych epokach agent nie zdążył jeszcze sie nauczyć omijania klifu i naliczane są mu kary za każdym razem jak wpadnie do dziury. Na powyższych wykresach możemy też zaobserwować że dla większych learning rate szybciej znajdywana jest najkrotsza droga.

3 Podsumowanie

- learning rate w granicach 0.3 - 1 jest odpowiedni
- za mała maksymalny limit kroków w epoce może skutkować zbyt szybkim przerywaniem uczenia się agenta